



מבוא למדעי הנתונים 1 - תרגיל בית 2

הנחיות הגשה: יש לכתוב את הפתרונות שלכם במחברת jupyter notebook ובסיום ביצוע התרגיל להגיש את הקובץ ipynb לתיבת הגשה ב- Moodle בשם (לדוגמא):

HW3_123456789.ipynb

כאשר 123456789 זה הת.ז. שלכם וHW3 מסמן שזה תרגיל בית שלישי.

שאלה מס' 1:

הורידו את הקובץ הכולל שאלות שקונים שאלו באתר Amazon.com לגבי כלי נגינה שונים שהם רכשו. כתוב להורדה:

https://datarepo.eng.ucsd.edu/mcauley_group/data/amazon/qa/qa_Musical_Instruments.json.gz

כתבו קוד פייתון הטוען את הקובץ ומבצע את הניתוחים הבאים:

1. מה הן 20 המילים הכי נפוצות שמופיעות בשאלות של הקונים.
2. מה הן 20 המילים הכי נפוצות שמופיעות בתשובות על השאלות.
3. מה הוא האורך הממוצע של השאלות (במילים וגם בתווים).
4. היסטוגרמה של אורכי התשובות במילים. (כלומר גרף שמראה כמה תשובות יש שכוללות רק מילה אחת, שתי מילים, שלוש מילים וכך הלאה). את התשובות שכוללות יותר מ-30 מילים ניתן לאחד לקבוצה אחת של +30.

שאלה מס' 2:

הורידו את הקובץ הכולל 5000 הודעות SMS מחולק לשתי קטגוריות: ספאם והודעה רגילה. כתוב להורדה:

<https://www.kaggle.com/datasets/uciml/sms-spam-collection-dataset>

1. כתבו קוד פייתון הטוען את הקובץ ומוצא אילו מילים הכי נפוצות בקטגוריה של ספאם בקטגוריה של הודעות רגילות.
2. חישוב את ה KL Divergence של המילים בהודעות של ספאם לעומת ההודעות הרגילות וההפך (בדומה למה שעשינו בשיעור), הציגו את top-20 מילים ייחודיות להודעות ספאם ו top-20 מילים ייחודיות להודעות הרגילות.
3. לכל מילה בשתי הרשימות שמצאתם בסעיף הקודם, מצאו את ה-5 מילים הנפוצות ביותר שמופיעות בהכי הרבה הודעות ביחד עם המילים מהרשימות.